

基于多模态知识图谱的服装推荐算法^{*}

万晓慧 李维乾 贺 妮 邓玉琼
(西安工程大学计算机科学学院 西安 710600)

摘要 现有的服装推荐算法存在模型可解释性不强,用户信息聚合不够全面的问题。论文引入了双聚合优化策略,对KGAT模型进行了改建,以此为基础设计了一种基于多模态知识图谱的服装推荐模型——MDPKT。该模型将文本信息(用户品牌信息、服装主体属性等)以及视觉信息(服装图片)数据来源,转换为作为知识协作知识图,将品牌信息、服装主体的协作知识图传入到改进后的KGAT模型中;将服装图片视觉协作知识图传入到Resnet50预训练模型训练,将两类模型提取到的特征值传入图神经网络进行表示学习。引入的双聚合优化策略,能够动态地选择用户层以及项目层的最佳聚合跳数,使得信息的流通更为完备;改进后的KGAT更好地挖掘用户与项目之间的潜在偏好关系,可以有效提升模型的精确度。该模型在IQON10数据集以及IQON3000数据集上进行了实验,结果表明,该模型与其他基准模型相比可以获得更好的性能,论文模型在IQON10数据集上的提升效果更为明显,与SOTA模型相比,MDPKT在AUC、Recall@20、NDCG@20各个指标上分别有5.99%、5.12%、5.01%的显著提升,在IQON3000上这些指标分别提升了4.71%,8.1%和4.21%。

关键词 服装推荐算法;多模态;知识图谱;双聚合策略

中图分类号 TP391.3 DOI:10.3969/j.issn.1672-9730.2025.03.026

Multi-modal Clothing Recommendation Algorithm Based on Knowledge Graph

WAN Xiaohui LI Weiqian HE Ni DENG Yuqiong
(School of Computer Science, Xi'an Polytechnic University, Xi'an 710600)

Abstract The existing clothing recommendation algorithms have problems with weak interpretability of models and incomplete aggregation of user information. This article presents a novel clothing recommendation model called the multi-modal dual policy knowledge graph (MDPKT), which enhances interpretability and aggregates user information more effectively. The MDPKT model integrates multi-modal data—textual information like brand and clothing attributes, and visual data from clothing images—into a unified knowledge graph. It employs an improved KGAT model and a ResNet50 pre-training model to process textual and visual data, respectively. A key feature the paper introduced in is the dual aggregation optimization strategy, which optimally selects the number of aggregation hops for both users and items, improving information flow and model accuracy. The model is experimented on the IQON10 dataset and the IQON3000 dataset. The results show that this model can achieve better performance compared with other benchmark models. The improvement effect of the model proposed in this paper on the IQON10 dataset is more obvious. Compared with the SOTA model, MDPKT has significant improvements of 5.99%, 5.12%, and 5.01% in AUC, Recall@20, and NDCG@20 respectively. On the IQON3000 dataset, these indicators have increased by 4.71%, 8.1%, and 4.21% respectively.

Key Words fashion recommendation, multi-model, knowledge graph, dual aggregation policy

Class Number TP391.3

1 引言

在服装电子销售中,服装推荐系统是主力的工

具。它的目标就是在庞大的物品数据库中,基于用户与商品的历史交互信息来预测用户可能会感兴趣的小部分商品集合。为用户推荐当前最为合适

* 收稿日期:2024年9月15日,修回日期:2024年10月22日

基金项目:教育部重点实验室开放基金项目(编号:NS202118901)资助。

作者简介:万晓慧,女,硕士研究生,研究方向:深度学习、自然语言处理。李维乾,男,副教授,研究方向:大数据、深度学习、3S技术等。贺妮,女,硕士研究生,研究方向:深度学习、自然语言处理。邓玉琼,女,硕士研究生,研究方向:深度学习、自然语言处理。

的商品,缓解信息过载问题,以此来加速并促进用户的购买行为,增加平台的用户粘性与流水。

传统的推荐算法^[1-3]大体上分为三种:基于内容的推荐、协同过滤推荐和混合推荐,过传统推荐算法都存在严重的数据稀疏和冷启动问题,随着近些年来深度学习理论的快速发展,深度学习在很多领域如计算机视觉和文本类任务等都取得了巨大的成功,也在一定程度上解决了数据稀疏和冷启动问题。服装推荐算法也逐步从传统推荐方法转为利用深度学习神经网络挖掘学习用户与项目之间的关系,以此来进行评分预测。目前,在基于多模态信息的服装推荐算法研究中,主流模态信息一般为图片类模态信息和文本类模态信息。

Li 等^[4]在服装分类实验中采用了不同的神经网络,较传统方式而言,结果获得了不小的提升。Jiang 等^[5]采用迁移学习的思想,针对缺少服装图像数据的问题,使用 ResNet 提取基础特征,获得了在图像分类方向上表现优秀的深度学习模型。Zhang 等^[6]在中提出了基于 Mask-RCNN 的服装识别和分割技术,在特征提取方面,则采取的是 ResNet 结合 FPN 的方法。尽管通过传统推荐系统及结合深度学习等新兴方法提高了推荐系统的精确度与效率。但目前的算法模型中深度学习的应用都只是对图片和文本所包含的信息进行简单的浅层提取,忽略了服装实体所包含的某些不可见特征,对视觉图片信息的获取不够深入,并且对于引入信息所带来的噪声处理也不够完备,在搭建的协同知识图谱中对用户和物品邻居节点的聚合策略也是固定的,无法针对所学习的实体的不同而选取合适的聚合跳数,造成对用户的偏好获取与预测不够深入,同时模型的可解释性也不够强。

针对上述问题,本文提出了一种基于多模态知识图谱的服装推荐算法模型 MDPKT,融合知识图谱和图神经网络,对于协同知识图谱的结构也做了一定的改进,主要贡献如下:

- 1) 增加用户-品牌协同知识图,对用户的兴趣挖掘更为深入全面。
- 2) 使用多模态数据,不同种数据信息之间互相补充增强,丰富了最终的实体嵌入表示。
- 3) 引入双聚合策略,动态选择实体的聚合层数,达到更好的信息获取效率以及更全面的嵌入表示。
- 4) 本文模型在真实的数据集 IQON10 以及 IQON3000 上进行了实验,针对目前的基准模型来说均有提升,体现了本文算法的优越性。

2 相关技术

2.1 融合图神经网络的推荐算法

图卷积神经网络^[7-9]是当前主流推荐算法当中应用较为广泛的网络架构。它是一种用于处理图数据的神经网络模型,通过对节点和边进行卷积操作来实现特征的提取,可分为三个部分,分别是节点嵌入层、图卷积操作层和预测层^[10]。图为 G ,节点集合 V ,节点之间连接的边集合 E :

$$G = (V, E) \quad (1)$$

在节点嵌入层中的操作即对图 G 上的节点进行编码,得到相关节点的嵌入向量表示。

在图卷积操作层中,会对实体节点的特征嵌入信息表示进行更新迭代。经过多次重复步骤,获得聚合了高阶邻居信息的用户实体节点向量表示。

在预测层中则是通过节点嵌入层和多层图卷积层,得到最终的用户节点嵌入向量表示(x_u^1, \dots, x_u^l)和项目节点嵌入表示(x_v^1, \dots, x_v^l)。此时,可以对我们需要做出预测的指定用户 u 和指定项目 v 之间进行推荐预测并得到最终评分。

2.2 融合注意力机制的图神经网络推荐算法

在初代的神经网络算法中,研究者逐渐发现在针对某一实体时,人们往往会基于自身的个性化特征从而对不同的部分分配不同的注意力比重。因此,注意力机制^[11]被提出并进入了研究者们的视野。知识图注意网络(KGAT)模型^[12]基于协同知识图(CKG)构建,它将用户交互历史行为和项目知识信息融合编码为一个统一的关系图,这样就可以融合协同过滤信息及知识图谱信息,同时也可以通过协同知识图发现更高阶的关系信息,模型框架如图 1 所示。

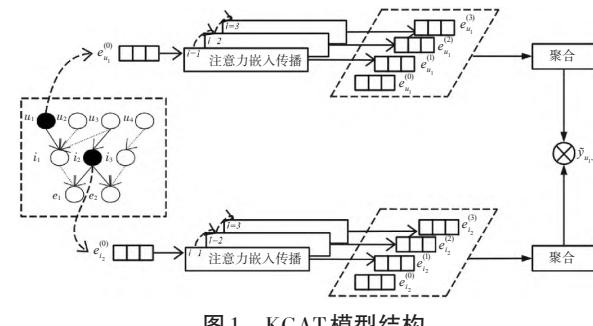


图 1 KGAT 模型结构

KGAT 模型主要由三部分组成:

- 1) 嵌入层,保留 CKG 的结构,使用 TransR^[13]方法学习节点和边的向量表示。
- 2) 注意力嵌入传播层,节点表示信息是通过递归传播节点邻居的嵌入信息进行更新的,在传播过

程中,通过注意力机制的引入学习来根据不同邻居节点的重要性分配不同的权重。

3) 预测层,经过 L 层传播,最终得到用户节点 u 的多个表示形式。

2.3 深度Q网络

深度Q网络^[14](Deep Q-Network, DQN)是2013年由谷歌团队提出的一种深度强化学习算法,用于解决基于值函数的强化学习问题。它的核心思想是使用深度神经网络来近似值函数 $Q(s, a)$,其中 s 表示状态, a 表示动作。深度神经网络可以处理高维的状态和动作空间,并通过反向传播算法来更新网络的参数,从而实现对值函数的优化。

在DQN算法中,智能体通过与环境的交互来学习最优策略,通过观察环境的状态,选择一个动作,并接收环境的奖励信号来评估动作的好坏。通过不断地与环境交互,智能体通过优化值函数来最大化累积奖励。

3 MDPKT模型

现有的推荐算法中使用的神经网络存在用户的信息聚合的不够全面且没有考虑到多种模态的使用,因此本文设计并提出了一种基于多模态知识图谱的服装推荐模型-MDPKT。本文提出的基于多模态知识图谱的服装推荐算法模型结构如图2所示,主要分为协同知识图谱的搭建学习以及KGAT的改进结构两部分。

3.1 面向属性的协同知识图

我们首先将每个用户行为表示为一个三联体 $(u, \text{交互}, i)$,其中 $y_{ui}=1$ 表示为用户 u 和项目 i 之间

的附加关系交互。然后基于项目-实体对照集,用户-项目图可以与知识图谱无缝集成,作为统一图 $G=\{h, r, t | h, t \in E, r \in R\}$ 。

在推荐系统的应用场景中,所提供的数据集通常会包含有用户和项目的交互信息,例如购买行为或点击行为。这里我们将用户和项目之间产生的交互信息表示为用户项二部图 G_1 ,定义为 $G_a=\{u, y_{ui}, i | u \in U, i \in I\}$, U 和 I 分别表示用户集和项目集,代表用户和项目之间的交互关系, $y_{ui}=1$ 表示用户和项目之间产生过交互,没有过历史交互则 $y_{ui}=0$ 。之后将用户项目二部图和知识图谱结合起来形成面向属性的三元知识协同图 G_1 。 $G_1=\{h, r, t | h, t \in P, r \in R\}$, P 代表用户集与项目集和属性集的并集, R 是实体之间的关系集合。

3.2 面向品牌的协同知识图

在用户的购买点击记录中,我们发现品牌与用户的购物偏好有很大的联系,且关注度要远远大于其他因素。因此,构建一个用户品牌二部图 G_b ,定义为 $G_b=\{u, y_{ub}, b | u \in U, b \in B\}$, U 和 B 分别表示用户集和品牌集, $y_{ub}=1$ 代表用户与品牌之间的交互次数大于等于5次,其余情况 $y_{ub}=0$ 。

后续的知识图嵌入学习方法采用的是TransR方法,使用BPR损失函数进行模型的优化,以最大化真实存在的正例三元组 $g(h, r, t)$ 与随机构造的负例三元组 $g(h, r, t')$ 之间的距离差值为目标,可表示为

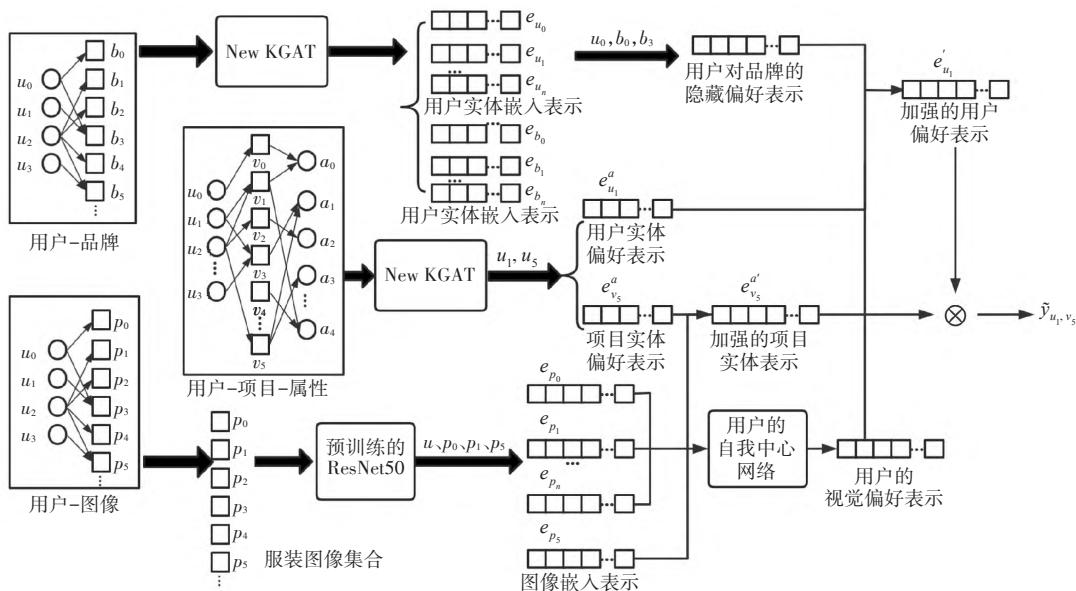


图2 MDPKT模型结构

$$\mathcal{L}_{GE} = \sum_{(h,r,t)} \ln \sigma(g(h,r,t) - g(h,r,t')) + \lambda \|\Theta_1\|_F^2 \quad (2)$$

$$g(h,r,t) = \|e_{h_r} + e_r - e_{t_r}\|_2^2 \quad (3)$$

在式(2)和式(3)中, $\sigma(\cdot)$ 是 sigmoid 函数, Θ_1 是图嵌入过程中的参数, λ 是一个非负的超参数, $e_r \in R^d$ 代表了关系类型 r 待学习的初始嵌入向量表示, e_{h_r} 和 e_{t_r} 表示头实体 h 和尾实体 t 在对应的关系类型 r 的空间的投影表示。最终通过优化 \mathcal{L}_{GE} , 就可以得到面向属性以及品牌协同知识图中的所有实体以及关系类型的嵌入向量表示。

3.3 面向图像的协同知识图

将用户与其有过交互记录的服装图片连接到一起形成一个用户-服装图像的二元协同知识图, 将服装图片送到预训练网络模型 Resnet50 里进行训练提取出服装实体的初步视觉特征, 之后引入一个 MLP 来对初步特征嵌入进行降维与微调得到 e_p^u , 为了后续的偏好预测计算, 将视觉特征的维度调整至与属性特征的偏好嵌入一致的维度 d 。

3.4 双向聚合策略和 KGAT 的融合

基于 GNN 的推荐系统通过聚合来自遥远邻居的信息来捕获用户与项目之间复杂的高阶连接, 提高推荐系统的性能。可是大多数模型的聚合条数都是固定的, 很难找到一个合适的参数是的绝大多数实体都能够比较高效快速地聚合到自己所需要的信息, 于是提出了双向聚合策略, 能够自适应地选择聚合的跳数, 高效地聚合周围邻居中自己所需要的信息。DQN 是指基于深度学习的 Q 学习算法, 采用了目标网络和经历回放的方法进行网络的训练。

图 3 的左侧是用户-项目实体二部图。随后是用户 DQN 和项目 DQN 的马尔科夫决策过程。对用户 DQN 进行项目级抽样, 对项目 DQN 进行用户级抽样。然后是自己采用的图神经网络模型, 它将初

始采样的用户和项目实体节点(图 3 中的 u_a, v_d)作为状态, 并将它们映射到用户和项目状态(图 3 中 2 和 3)的操作(即跳数)。换句话说, 用户或项目状态的跳数操作决定了后续利用多少相应的 GNN 层来获得最终的嵌入并计算用户-项目匹配分数。每个状态动作元组都在其进行的过程中累积。例如($u_a, 2$)被保存在用户的元组列表 L_u 中, 并且($v_d, 3$)被保存在 L_v 中。根据给定的动作, 它堆叠动态调整的 GNN-R 层, 本文采用的是 KGAT, 实现最终的嵌入。通过项目抽样获得用户的奖励, 通过用户抽样获得用户的奖励, 从嵌入中获得的奖励值被用来更新后接的双 DQN。最终得到了我们优化后的 KGAT 模型。

在本文所提出的模型中, 如本章前几小节所示建立完成三个协同知识图后, 分别将其传入如图 3 所示的神经网络中进行特征表示学习, 再如图 2 所示将表示进行优化。

首先, 令 $N_h = \{(h, r, t) | (h, r, t) \in G\}$ 表示 h 是头实体的三元组集合, 则传递所有以 h 为头实体的三元组 (h, r, t) 的尾向量 e_t 的信息为

$$e_{N_h} = \sum_{(h, r, t) \in N_h} \pi(h, r, t) e_t \quad (4)$$

在式(4)中, $\pi(h, r, t)$ 是衡量消息 (h, r, t) 重要程度的权重, 表示有多少信息以 r 为条件从尾实体向量 e_t 传递到头实体向量 e_{N_h} , 权重越大, 则传递的信息越多, 其具体的实现如下:

$$\pi(h, r, t) = (W_r e_t)^T \tanh(W_r e_h + e_t) \quad (5)$$

其次, 对注意力得分采用 softmax 函数进行标准化, 即:

$$\pi(h, r, t) = \frac{\exp(\pi(h, r, t))}{\sum_{(h, r, t) \in N_h} \pi(h, r, t)} \quad (6)$$

最后, 采用双交互聚合器聚合所有传播层的用

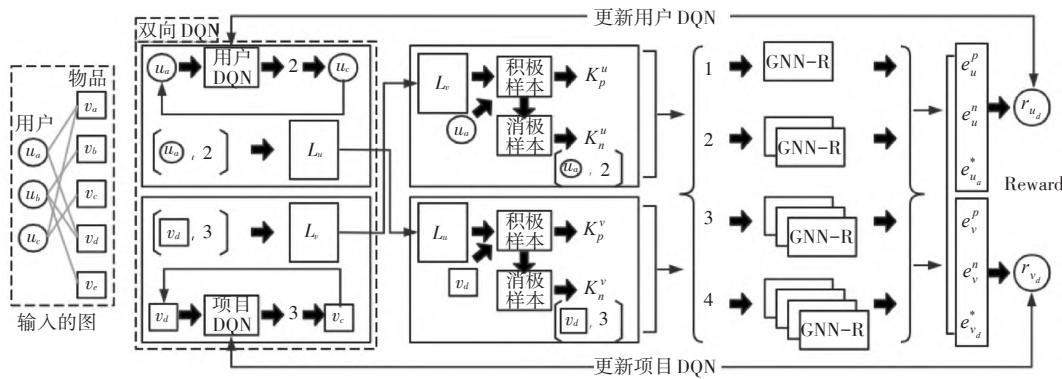


图 3 双向聚合学习策略

户和项目的表示为

$$\begin{aligned} f_{Bi-Interaction} = & \text{Leaky ReLU}\left(W_1\left(e_h + e_{N_h}\right)\right) \\ & + \text{Leaky ReLU}\left(W_2\left(e_h \odot e_{N_h}\right)\right) \end{aligned} \quad (7)$$

在式(7)中, $W_1, W_2 \in R^{d' \times d}$ 为可训练权重矩阵, \odot 表示元素乘积。双交互聚合器考虑 e_h 和 e_{N_h} 之间的特征交互, 目的是使得传播的信息更关注两者之间的关联性, 从而使相似的实体之间传递更多的消息。经过 L 层传播, 最终得到用户节点 u 的多个表示形式, 即 $\{e_u^{(1)}, \dots, e_u^{(L)}\}$, 同样地, 可以得到项目节点的多个表示形式, 即 $\{e_i^{(1)}, \dots, e_i^{(L)}\}$ 。由于不同传播层的输出强调不同阶的连通信息, 所以采用层聚合机制将每一层的表示聚合成一个向量:

$$e_u^* = e_u^{(0)} \| \cdots \| e_u^{(L)} \quad (8)$$

$$e_i^* = e_i^{(0)} \| \cdots \| e_i^{(L)} \quad (9)$$

在式(8)和式(9)中, $\|$ 是拼接操作, 通过调整 L 来控制嵌入传播的阶数, 丰富初始嵌入。得到用户实体、品牌实体、服装实体和服装图像的初始嵌入特征表达 e_u, e_b, e_v^a, e_p 、用户实体的隐层偏好嵌入表示 e_u^a 。指定用户实体 u_1 和服装实体 v_5 后, 可以得到用户对品牌的偏好嵌入表示 $e_{u_1}^b$ 、用户的视觉偏好表示 $e_{u_1}^p$ 。

$$e_{u_1}' = e_{u_1}^p \odot e_{u_1}^b \odot e_{u_1}^a, e_{v_5}' = e_{v_5} \odot e_{v_5}^a \quad (10)$$

$$\hat{y}_{u_1, v_5} = (e_{u_1}')^T \cdot e_{v_5}' \quad (11)$$

通过向量逐个相乘运算得到加强的用户偏好表示 e_{u_1}' 以及加强的服装实体嵌入表示 e_{v_5}' 。通过内积衡量用户实体 u_1 和服装实体 v_5 最终表示的相似度, 并做出最终预测, 得到结果。

4 实验分析

4.1 数据集

为了验证 MDPKT 的性能, 本模型在如表 1 所示的服装数据集 IQON3000^[15] 和 IQON10 上进行实验。IQON10 是依托于公开服装数据集 IQON3000 构造出的适合于个性化服装推荐任务的数据集。IQON3000 是基于真实世界中的具有丰富属性标注以及视觉图像信息的服装数据集, 针对服装套装推荐任务, 包含有 3 568 位用户, 308 747 个套装以及 672 335 件服装, 图 4 为部分样本示例。其中每个服装实体都有相匹配的服装图像, 并且也对其进行属性划分关联, 划分的属性类别多达 11 种, 包括价格、颜色、品牌等。



图 4 IQON3000 部分视觉信息样本示例

本文采用的 IQON10 数据集, 为了保证数据集的质量, 过滤掉了与用户交互次数少于 10 次的服装实体。最后得到如表 1 所示的数据集 IQON10 以及 IQON3000。将数据集按照 9:1 分别划分为训练集和测试集。为了便于处理与后续计算, 本文将服装实体图像的格式统一为 3*150*150, 优化器选用 Adam 方法(自适应动量估计法)。最终发现模型在正则化参数 $\lambda = 10^{-5}$, 维度 $d=64$, 学习率 $l_r = 0.0001$ 时取得的效果最佳。

表 1 数据分布表

Property	IQON10	IQON3000
User	3 568	3 568
Items	23 363	672 335
User-Item Interaction	459 146	10 295 654
Attribute Types	11	11
Attribute Values	3 019	3 019
Item-Attribute Association	153 020	4 397 276

4.2 实验环境与分析

为了验证本文模型有效性, 本文模型与基准模型 CKFG^[16]、KGAT、JNSKR^[17]、SAERS^[18] 以及 DoubleQ^[19] 五种模型在数据集 IQON10 和 IQON3000 上进行对比实验。实验结果如表 2、表 3 所示, 为了更加直观表示, 对表格中取得最高结果的数值进行加粗处理。

表 2 IQON10 数据集上模型对比实验

Model	AUC	R@20	N@20
CKFG	0.892 3	0.185 0	0.094 6
KGAT	0.790 5	0.164 5	0.090 0
JNSKR	0.893 9	0.208 8	0.100 6
SAERS	0.823 9	0.189 0	0.125 5
DoubleQ	0.893 5	0.210 8	0.123 1
MDPKT	0.947 5	0.221 6	0.131 8

表3 IQON2000数据集上模型对比实验

Model	AUC	R@20	N@20
CKFG	0.843 7	0.152 6	0.091 0
KGAT	0.802 9	0.143 0	0.082 5
JNSKR	0.821 1	0.179 7	0.073 6
SAERS	0.794 0	0.153 7	0.104 5
DoubleQ	0.821 5	0.163 0	0.098 0
MDPKT	0.883 5	0.194 3	0.108 9

结果表明本文模型在各个指标上都优于所有基线模型,高结果的数值进行加粗处理。结果表明本文模型在各个指标上都优于所有基线模型,这验证了本文提出模型的有效性。

本文模型在IQON10数据集上的提升效果更为明显,与SOTA模型相比,MDPKT在AUC、Recall@20、NDCG@20分别有5.99%、5.12%、5.01%的显著提升,指标对比如图5、图6所示。这表明了本文提出的模型能更好地挖掘用户对服装单品的偏好,在服装推荐算法模型上的优越性。

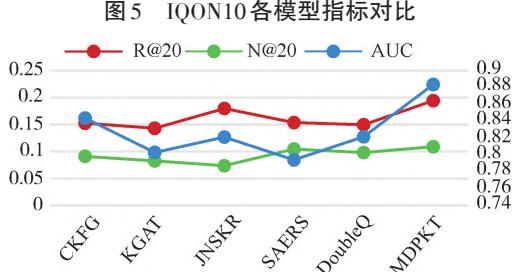
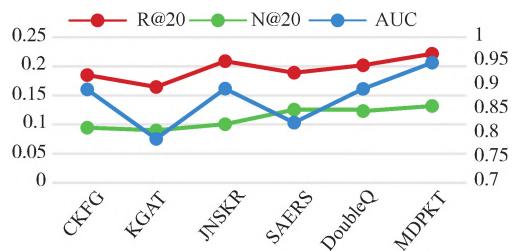


图6 IQON3000各模型指标对比

表4 IQON10模型消融实验

Model	AUC	R@20	N@20
DPKT	0.937 4	0.208 0	0.120 5
MKGAT	0.890 0	0.205 2	0.100 7
MDPKT-noKT	0.802 1	0.163 7	0.092 3
MDPKT	0.947 5	0.221 6	0.131 8

为了研究本文模型在多模态、KGAT和双聚合策略的应用有效性,在表4中展示了消融实验结果对比,实验所用数据集为IQON10。DPKT模型去除了视觉信息学习,参数指标均有一定的降低,证明了多模态对于模型的提升效果。MKGAT模型去除了双向选择策略,参数指标均有一定的降低,证明了双向聚合策略的应用对于模型的提升效果。

MDPKT-noKT模型将KGAT替换为普通的图神经网络,参数指标有较大幅度的降低,证明了KGAT网络对于模型的提升效果。

5 结语

本文针对现有服装推荐模型对用户信息的聚合不够全面、模态信息融合度不够、模型可解释性不够强的问题提出了一种基于多模态知识图谱的服装推荐模型,利用用户信息以及与用户产生过交互的服装实体的文字属性与图片信息进行个性化服装推荐预测。本文提出的模型将服装实体的文字属性信息与图像信息互相融合增强,丰富了服装实体的自身特征表达,也加强了用户对于服装实体的偏好表达,更好地挖掘出用户感兴趣的服装单品。并且对KGAT网络进行了改进,自适应地选择合适的聚合策略,对信息进行更优化快速地学习。在服装数据集IQON10以及IQON3000上的实验表明,与其他服装推荐基线模型相比,本文提出的模型是有效的,提高了服装推荐算法模型的性能。

参考文献

- [1] A Ko H, Lee S, Park Y, et al. A survey of recommendation systems: recommendation models, techniques, and application fields [J]. Electronics, 2022, 11(1): 141.
- [2] Roy D , Dutta M. A systematic review and research perspective on recommender systems [J]. Journal of Big Data, 2022, 9(1): 59.
- [3] Etemadi M, Abkenar S B, Ahmadzadeh A, et al. A systematic review of healthcare recommender systems: Open issues, challenges, and techniques [J]. Expert Systems with Applications, 2023, 213: 118823.
- [4] Li Y, Huang R , Dong A. Fashion style recognition based on an improved Bilinear-CNN [J].Journal of Donghua University (Natural Science), 2021, 47(03):90–95.
- [5] 江慧,马彪.基于服装风格的款式相似度算法[J].纺织学报,2021,42(11):129–136.
- [6] 张泽堃,张海波.基于Mask-RCNN的服装识别与分割[J].纺织科技进展,2020(06):20–24,32.
- [7] Liu C, Li Y, Lin H , et al. GNNRec: Gated graph neural network for session-based social recommendation model [J]. Journal of Intelligent Information Systems, 2023, 60 (1): 137–156.
- [8] Chen Gao, Yu Zheng Nian Li , et al. A survey of graph neural networks for recommender systems: Challenges, methods, and directions [J].ACM Transactions on Recommender Systems (Singapore) 2023, 1(1): 1–51.
- [9] Gwadabe T R, Liu Y. Improving graph neural network for

- session-based recommendation system via non-sequential interactions [J]. Neurocomputing, 2022, 468 (11) : 111–122.
- [10] Verma S, Zhang Z L. Graph capsule convolutional neural networks[J]. Arxiv Preprint Arxiv:1805.08090, 2018.
- [11] GUO Menghao, XU Tianxing, LIU Jiangjiang, et al. Attention mechanisms in computer vision: A survey [J]. Computational Visual Media, 2022, 8: 331–368.
- [12] Wang X, He X, Cao Y, et al. KGAT: knowledge graph attention network for recommendation [C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining, 2019: 950–958.
- [13] L Asmara S M, Sahabudin N A, Ismail N S N, et al. A Review of Knowledge Graph Embedding Methods of TransE, TransH and TransR for Missing Links[C]// Proceedings of 2023 IEEE 8th International Conference On Software Engineering and Computer Systems, 2023: 470–475.
- [14] ZHANG Lianhong, ZHOU Wenqi, XIA Junjuan, et al. DQN-based mobile edge computing for smart Internet of vehicle[J]. EURASIP journal on advances in signal processing, 2022, 1:1–16.
- [15] Song X, Han X, Li Y, , et al. GP-BPR: Personalized Compatibility Modeling for Clothing Matching [C]//Proceedings of the 27th ACM International Conference on Multimedia, 2019:320–328.
- [16] Ai Q, Azizi V, Chen X, et al. Learning heterogeneous knowledge base embeddings for explainable recommendation [J]. Algorithms, 2018, 11(9): 137.
- [17] Chen C, Zhang M, Ma W, , et al. Jointly non-sampling learning for knowledge graph enhanced recommendation [C]//Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval , 2020: 189–198.
- [18] Hou M, Wu L , Chen E , et al. Explainable Fashion Recommendation: A Semantic Attribute Region Guided Approach [C]//Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19), 2019:4681–4688.
- [19] Zhang Q, Cai G, Guo W, et al. Fashion Recommendation with a real Recommender System Flow[C]//Proceedings of the Recommender Systems Challenge, 2022: 4–9.

(上接第 118 页)

5 结语

本文分析了陆上模拟舰船平台的建设需求,研究了舰船运动特性模拟的关键技术,提出了一种基于无人驾驶技术的模拟运动舰船系统设计思路。该系统可根据需求调整车辆编队规模、车距、速度、行驶路径等参数,模拟不同类型舰船平台的运动特性。还可搭载雷达散射等目标特性模拟源,模拟舰船的其他目标特性,可为开展相关试验任务提供有效的平台支撑。

参 考 文 献

- [1] 司炳山,董志明. 外军无人系统自主行为决策技术发展研究[J]. 舰船电子工程,2022,42(12):8–11,52.
- [2] 王家凯,应运. 无人化装备作战应用及发展趋势研究[J]. 舰船电子工程,2021,41(11):5–7,27.
- [3] 赵熙俊,陈慧岩. 智能车辆路径跟踪横向控制方法的研究[J]. 汽车工程,2011,33(5):383–387.
- [4] 明延友. 智能汽车的轨迹跟随控制研究[D]. 长春:吉林大学,2016:23–29.
- [5] 冀杰,李以农,郑玲,等. 车辆自动驾驶系统纵向和横向运动综合控制[J]. 中国公路学报,2010,23(5):119–126.
- [6] 方钢,雍岐卫,赵延涛,等. 地面无人装备在后勤保障中的应用模式研究[J]. 舰船电子工程,2023,43(3):7–10.
- [7] 陈杨. 基于轨迹片段的运动规划方法及其在自主车辆中的应用[D]. 长沙:国防科技大学,2006:13–19.
- [8] 丁海涛,郭孔辉,陈虹. 汽车稳定性控制中横摆力矩决策的LQR方法[J]. 吉林大学学报(工学版),2010(3):597–601.
- [9] 张琨. 智能汽车自主循迹控制策略研究[D]. 哈尔滨:哈尔滨工业大学,2013:36–41.
- [10] 何文锋. 一种无人驾驶汽车差动转向路径跟踪控制器研究[J]. 舰船电子工程,2018,38(10):65–68.
- [11] 闫春娟. 基于非线性数学模型的舰船运动特性分析[J]. 舰船科学技术,2021,43(8):1–3.
- [12] 熊璐,康宇宸,张培志,等. 无人驾驶车辆行为决策系统研究[J]. 汽车技术,2008(8):1–9.